UNIVERSIDADE ESTADUAL DE MARINGÁ
DEPARTAMENTO DE INFORMÁTICA
CURSO DE BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

BEATRIZ AVANZI ECLI
Orientador: Prof. Dr. Wagner Igarashi

OTIMIZAÇÃO DE UM PORTFÓLIO DE AÇÕES UTILIZANDO O ALGORITMO DE TÊMPERA SIMULADA

Maringá, PR
2024

UNIVERSIDADE ESTADUAL DE MARINGÁ
DEPARTAMENTO DE INFORMÁTICA
CURSO DE BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

BEATRIZ AVANZI ECLI

OTIMIZAÇÃO DE UM PORTFÓLIO DE AÇÕES UTILIZANDO O ALGORITMO DE TÊMPERA SIMULADA

Monografia do Trabalho de Conclusão de Curso apresentada ao Curso de Ciência da Computação da Universidade Estadual de Maringá como parte dos requisitos necessários para a obtenção do grau de Bacharel em Ciência da Computação.

Orientador: Prof. Dr. Wagner Igarashi

Maringá, PR
2024

Ecli, Beatriz A.

Otimização de um Portfólio de Ações utilizando o algoritmo de Têmpera Simulada/ Beatriz Avanzi Ecli. –, 2024-

38 p. 1 :il. (colors; grafs; tabs).

Orientador: Prof. Dr. Wagner Igarashi

Monografia do Trabalho de Conclusão de Curso – Universidade Estadual de Maringá, Centro de Tecnologia - CTC, Departamento de Informática, 2024.

1. Otimização e diversificação de portfólio. 2. Têmpera Simulada. 3. Recozimento Simulado. 4. Simulated Annealing. 5. Ações. I. Prof. Dr. Wagner Igarashi. II. Universidade Estadual de Maringá. III. Otimização de um Portfólio de Ações utilizando o algoritmo de Têmpera Simulada

Beatriz Avanzi Ecli

OTIMIZAÇÃO DE UM PORTFÓLIO DE AÇÕES UTILIZANDO O ALGORITMO DE TÊMPERA SIMULADA

Monografia do Trabalho de Conclusão de Curso apresentada ao Curso de Ciência da Computação da Universidade Estadual de Maringá como parte dos requisitos necessários para a obtenção do grau em Bacharel em Ciência da Computação.

Aprovada em Maringá, 24 de Fevereiro de 2024.

Prof. Dr. Wagner Igarashi
UNIVERSIDADE ESTADUAL DE MARINGÁ
Orientador

Prof. Dra. Valéria Delisandra Feltrim
Universidade Estadual de Maringá
Examinador

Prof. Dr. Igor da Penha Natal
Universidade Estadual de Maringá
Examinador

A todos que, em algum momento dessa caminhada, me ofereceram seu sincero sorriso e estenderam sua mão.

Agradecimentos

Agradeço aos professores do Departamento de Informática, por todos esses anos juntos, por sua maestria na arte da docência e por aceitarem trilhar esse difícil, porém tão importante, caminho da ciência em nosso país, trazendo contribuições tão significativas. Agradeço à minha família e aos meus amigos por estarem comigo antes e durante essa caminhada, me trazendo tanta alegria, motivação e estabilidade. Agradeço, em especial, ao meu orientador Prof. Dr. Wagner Igarashi, por todo o apoio intelectual e emocional que me deu durante a elaboração desse trabalho - ele foi muito importante para que eu não desistisse. Agradeço aos membros da banca, Profa. Dra. Valéria Delisandra Feltrim e Prof. Dr. Igor da Penha Natal, por sua disponibilidade e atenção ao meu trabalho, e por todo o conhecimento que puderam me transmitir durante essa graduação.

"A felicidade só é verdadeira quando compartilhada."

Henry David Thoreau

Resumo

Este estudo aplica a técnica de Têmpera Simulada, um método avançado de otimização, à gestão de portfólios de ações na B3, objetivando a maximização do retorno ajustado ao risco. Caracterizando-se como uma pesquisa experimental e aplicada, o trabalho define como objetivos a análise e seleção de indicadores de desempenho financeiro, a identificação de um conjunto diversificado de ações, a implementação e ajuste do algoritmo de Têmpera Simulada para otimização de portfólios, e a realização de simulações para avaliar a eficácia da estratégia proposta. A metodologia empregada combina revisão bibliográfica com análises quantitativas, utilizando dados históricos de mercado para modelar e testar o algoritmo. Os resultados demonstram que o algoritmo de Têmpera Simulada proporciona bons resultados para relação risco-retorno dos portfólios, superando algumas estratégias tradicionais de investimento e se mostrando como um aliado enquanto ferramenta para a tomada de decisões financeiras.

Palavras-chave: Otimização e diversificação de portfólio; Ações; Ativos financeiros; Simulated Annealing; Algoritmos de Otimização; Têmpera Simulada; Recozimento Simulado.

Abstract

This study applies the Simulated Annealing technique, an advanced optimization method, to the management of stock portfolios on B3, aiming to maximize risk-adjusted returns. Characterized as experimental and applied research, the work outlines objectives including the analysis and selection of financial performance indicators, identification of a diversified set of stocks, implementation and adjustment of the Simulated Annealing algorithm for portfolio optimization, and conducting simulations to evaluate the effectiveness of the proposed strategy. The employed methodology combines a literature review with quantitative analyses, using historical market data to model and test the algorithm. The results show that the Simulated Annealing algorithm provides good risk-return ratio outcomes for portfolios, surpassing some traditional investment strategies and proving to be a valuable ally as a tool for financial decision-making.

Keywords: Portfolio optimization and diversification; Stocks; Financial assets; Simulated Annealing; Optimization Algorithms.

Lista de Ilustrações

Lista de Tabelas

Lista de Abreviaturas e Siglas

UEM	Universidade Estadual de Maringá
DIN	Departamento de Informática
TS	Têmpera Simulada
AG	Algoritmo Genético
IS	Índice de Sharpe

Sumário

1 Introdução

Ao explorar a aplicação de algoritmos de otimização de portfólios financeiros, este estudo visa contribuir para a melhoria das tomadas de decisões de investidores, gestores de fundos e outros profissionais do mercado financeiro. A partir da análise dos resultados obtidos, pretende-se avaliar se o Modelo de Otimização proposto contribui para mais robustas e eficientes de alocação de recursos, apoiando, assim, para o aprimoramento do desempenho dos investimentos e potencialmente impactando positivamente o cenário econômico.

1.1 Justificativa

A busca por estratégias eficazes na administração de portfólios de ativos financeiros tem sido preocupação constante em cenários econômicos variáveis e muitas vezes imprevisíveis. Nesse contexto, a otimização ou diversificação de portfólios se destaca como abordagem fundamental para a maximização de retornos ou a minimização de riscos, levando em consideração as complexas interações entre diferentes ativos (MARKOWITZ, 1952).

Dentre as diversas técnicas de otimização computacionais que podem ser aplicadas para a otimização de portfólios, pode-se citar a Têmpera Simulada, uma técnica de otimização inspirada em processos físicos de recozimento, a qual tem se mostrado uma ferramenta valiosa para enfrentar desafios complexos em diversas áreas. Seu potencial reside na capacidade de explorar espaços de soluções extensos e complexos, superando mínimos locais e convergindo para soluções próximas do ótimo global (NIKOLAEV A. G. E JACOBSON, 2010). Ao aplicar o algoritmo de Têmpera Simulada ao problema de diversificação e otimização de portfólios de ações, buscou-se aproveitar essa capacidade para encontrar alocações de ativos que proporcionem uma combinação ideal de risco e retorno com foco em otimização.

A relevância deste estudo reside na contribuição para a eficiência das tomadas de decisões de investimento, pois pretende-se contribuir para a construção de um portfólio que considere de forma mais abrangente a volatilidade e a correlação entre os ativos, resultando em alocações que possam atingir uma relação quase ótima entre retorno e risco. Essa abordagem tem o potencial de melhorar a eficácia das estratégias de investimento, impactando positivamente a performance dos portfólios.

Além disso, o estudo pretende complementar o acervo de pesquisas acadêmicas no âmbito do uso de técnicas de otimização computacional aplicadas ao problema de portfólios de ações. A aplicação da Têmpera Simulada, que já apresenta sucesso em outros domínios, aporta um novo enfoque à gestão de portfólios, explorando uma abordagem matemática e sistemática para a construção de alocações diversificadas. Trás ainda informações complementares ao estudo proposto por Melquiades (2017), acadêmico também graduado pela Universidade Estadual de Maringá.

1.2 Objetivos

O objetivo geral deste trabalho é a obtenção de um portfólio de ações cotadas na B3 com maior diversificação possível de forma a otimizar o lucro e diminuir os riscos. A partir do objetivo geral, foram delineados os seguintes objetivos específicos:

1. Delimitação dos indicadores de desempenho de ações;
2. Seleção de um conjunto de ações cotadas na B3;
3. Seleção e implementação do algoritmo de otimização;
4. Análise de simulações de investimento e comparações com *benchmarks*.

1.3 Organização do Trabalho

O presente trabalho apresenta, além deste capítulo de caráter introdutório: o capítulo 2, o qual versa sobre a revisão bibliográfica relativa aos conceitos teóricos que fundamentam a realização deste estudo; o capítulo 3, que relata o desenvolvimento do estudo; o capítulo 4 onde são dispostos os resultados dos experimentos; o capítulo 5, onde são delineadas as conclusões e as possibilidades de estudos futuros; e, por fim, são descritas as referências bibliográficas e apêndices.

2 Revisão Bibliográfica

Na sequência, apresenta-se a base teórica, contextualizando o problema dentro do âmbito financeiro. Serão discutidos conceitos relevantes como métricas financeiras, a importância da diversificação e a otimização de portfólios de ativos, além de explorar alguns dos algoritmos de otimização frequentemente empregados para essas finalidades.

2.1 Contexto Financeiro

Segundo Shahid Mohammad e Shamim (2022), o problema da seleção de portfólio é dos problemas mais comumente discutidos por especialistas do mercado financeiro nas últimas décadas. A necessidade de tomar decisões de investimento informadas em um ambiente de risco e incerteza tem levado à busca constante por métodos que otimizem a alocação de recursos financeiros. Quando se trata de seleção de ativos, os conceitos de retorno e risco introduzidos por Markowitz (1952) deram origem à chamada Teoria de Portfólio. Essa teoria revolucionária propôs que, ao invés de analisar ativos individualmente, os investidores deveriam avaliar suas interações, especialmente quanto às variações negativas. Isso deu início a uma nova abordagem para a composição de portfólios de ativos no mercado financeiro, com foco na escolha de um conjunto de ativos que forme uma relação otimizada entre risco e retorno.

Nos dias atuais, a crescente disponibilidade de dados financeiros e os avanços na tecnologia de processamento computacional permitiram uma evolução significativa na forma como a Teoria de Portfólio é aplicada. Algoritmos de programação e técnicas de otimização se tornaram ferramentas essenciais para implementar os princípios da Teoria de Portfólio com eficiência e precisão. As abordagens tradicionais, muitas vezes baseadas em análises manuais e intuição, têm sido complementadas e, em alguns casos, substituídas por modelos matemáticos e algoritmos que podem lidar com grandes volumes de dados e considerar uma ampla gama de variáveis.

Diante do exposto, dentro do âmbito da Ciência da Computação, o problema de seleção de portfólio é visto, em muitos casos, como um desafio de otimização, onde o objetivo é encontrar a combinação de ativos que maximize o retorno esperado para um determinado nível de risco ou minimize o risco para um dado nível de retorno. Algoritmos canônicos de otimização, como a Têmpera Simulada mencionada anteriormente, têm sido aplicados com sucesso a esse problema. Esses algoritmos exploram estratégias de busca para encontrar soluções aproximadas ou exatas que atendam aos objetivos de otimização, considerando as restrições impostas pelo investidor e as características dos ativos.

2.2 Bolsas de Valores no Brasil

Uma breve contextualização histórica sobre as bolsas de valores do Brasil pode ser feita a partir de Neto (2014). Segundo ele, a Bovespa (Bolsa de Valores de São Paulo) foi a principal bolsa de valores do Brasil, responsável pelo mercado de ações. Foi fundada em 1890 e era uma das mais antigas bolsas de valores em operação no país.

Já a BM&F (Bolsa de Mercadorias & Futuros), fundada em 1986, foi a principal bolsa brasileira para negociação de contratos futuros, *commodities* e outros instrumentos financeiros.

A partir da fusão entre a Bovespa e a BM&F surgiu a BM&FBovespa em 2008, criando uma das maiores bolsas do mundo em valor de mercado. Essa fusão combinou as operações de mercado de ações (anteriormente na Bovespa) com o mercado de derivativos (anteriormente na BM&F), sob uma única entidade.

B3 (Brasil, Bolsa, Balcão) foi o nome adotado após a fusão entre a BM&FBovespa e a CETIP em 2017. A CETIP foi a principal provedora de serviços para o mercado de títulos privados e de derivativos de balcão no Brasil. Então, a partir de 2017, a B3 se tornou a única bolsa de valores do Brasil, abrangendo negociação de ações, futuros, moedas, títulos e valores mobiliários, entre outros serviços financeiros.

Ibovespa é o principal índice do mercado de ações brasileiro e reflete o desempenho de uma carteira teórica das ações mais negociadas na B3. Não é uma entidade ou instituição, mas sim um indicador que mostra como, em média, as ações listadas na bolsa estão se comportando. O Ibovespa serve como um termômetro para o mercado de ações brasileiro e é utilizado como referência para investidores.

2.3 Teoria de Portfólio

De acordo com Markowitz (1952), um Portfólio de Ativos é uma combinação específica de investimentos em diferentes ativos financeiros, como ações, títulos, fundos imobiliários, entre outros. A Teoria de Portfólio de Markowitz (1952) introduziu o conceito de diversificação como um meio de gerenciar o risco em um portfólio. Segundo Montini (2015):

> "O artigo pioneiro de Markowitz (1952) provocou uma mudança radical na forma de analisar o problema da formação de portfólios (grupos ou carteiras) de ativos financeiros. Diversos direcionamentos formados na teoria, conjuntamente explorados por outros pesquisadores clássicos como Sharpe (1964) e Lintner (1965), provocaram dúvidas, discussões e questionamentos, tendo como produto uma gama de livros e artigos que formaram a Moderna Teoria do Portfólio."

Na prática, ao tomar decisões financeiras, raramente se conta com certeza absoluta sobre os resultados esperados (NETO, 2014). De fato, dado que tais decisões estão intrinsecamente orientadas para acontecimentos futuros, torna-se crucial considerar a incerteza como um elemento central e significativo no estudo das atividades do mercado financeiro (NETO, 2014).

De acordo comMarkowitz (1952), a diversificação envolve a alocação de recursos entre diferentes tipos de ativos, de modo que as variações negativas no desempenho de um ativo possam ser compensadas pelo desempenho positivo de outro. Isso reduz a volatilidade total do portfólio e aumenta a probabilidade de alcançar um retorno médio mais estável ao longo do tempo.

Markowitz (1952) cita dois tipos de riscos possíveis para um portfólio, o Risco Diversificável e o Risco Sistemático. O Risco Diversificável é o risco que pode ser minimizado por uma ponderação adequada de investimentos selecionados para uma carteira. O Risco sistemático, por sua vez, trata-se do risco a que todas as empresas estão sujeitas no mercado de forma indistinta e que afeta a todas de forma igual. Portanto, esse risco não pode ser eliminado com o uso das carteiras ou portfólios de investimento.

O retorno esperado, ainda segundo Markowitz (1952), seria a medida do ganho médio ou perda média que um investidor pode esperar receber do seu portfólio de acordo com o investimento inicial feito. Ela será representada pelas medidas de variação do valor financeiro do portfólio em um determinado tempo.

Em resumo, é possível afirmar que a Teoria de Portfólio contribui para a busca de uma combinação próxima da combinação ótima de ativos que ofereça o maior retorno esperado para um determinado nível de risco (ou a menor variância para um dado nível de retorno), dependendo de quais modelos serão utilizados dos que focam em otimização ou diversificação. Markowitz (1952) também destacou a importância de considerar não apenas os ativos individualmente, mas da relação entre eles.

2.3.1 Otimização e Diversificação

É essencial estabelecer que o termo "otimização"adquire significados distintos conforme o campo de estudo em questão, seja na teoria financeira ou na ciência da computação. No âmbito da teoria de portfólios, a otimização de um portfólio refere-se à maximização do retorno, enquanto a diversificação refere-se à minimização dos riscos (MARKOWITZ, 1952). Em contrapartida, no contexto da ciência da computação, o processo de otimização implica tanto na maximização quanto na minimização de determinado parâmetro (WRIGHT, 2006). Portanto, torna-se primordial elucidar essas divergências conceituais.

2.4 Métricas de Risco e Retorno

2.4.1 Retorno de um Ativo

O retorno de um ativo é calculado pela variação percentual no preço do ativo em um determinado período (NETO, 2014).

$$R_{\text{ativo}} = \frac{P_{\text{final}} - P_{\text{inicial}}}{P_{\text{inicial}}} \times 100 \tag{2.1}$$

onde P_{final} é o preço final do ativo, e P_{inicial} é o preço inicial do ativo.

2.4.2 Retorno de um Portfólio

O retorno de um portfólio é a soma ponderada dos retornos dos ativos que compõem o portfólio (NETO, 2014).

$$R_{\text{portfólio}} = \sum_{i=1}^{n} w_i \cdot R_i \tag{2.2}$$

onde w_i é o peso do ativo i no portfólio, e R_i é o retorno do ativo i.

2.4.3 Risco de um ativo

O risco de um ativo pode ser representado pelo desvio padrão dos seus retornos (NETO, 2014).

$$\sigma = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N} (R_i - \bar{R})^2} \tag{2.3}$$

onde R_i é o retorno do ativo no período i, $\bar{R}$ é o retorno médio do ativo, e N é o número total de períodos.

2.4.4 Risco de um Portfólio

O risco de um portfólio é calculado a partir da matriz de covariância dos ativos que compõem o portfólio (NETO, 2014).

$$\sigma_{\text{portfólio}} = \sqrt{\mathbf{w}^T \Sigma \mathbf{w}} \tag{2.4}$$

onde $\mathbf{w}$ é o vetor de pesos dos ativos no portfólio, e Σ é a matriz de covariância dos retornos dos ativos.

2.5 Métricas de Análise Retorno e Risco

A seguir, têm-se uma breve explicação sobre algumas das principais métricas de análise que interligam Retorno e Risco, conforme delineado por Securato (2010) e Neto (2014).

Estas métricas são importantes para o processo de seleção de ativos em portfólios, visando à maximização de retornos ou à minimização de riscos. Destaca-se, particularmente no âmbito da ciência da computação, a importância dessas métricas na configuração da Função Objetivo em algoritmos de otimização. Tal função é essencial para direcionar os esforços de otimização, seja para alcançar a maximização ou a minimização, conforme os objetivos específicos da aplicação em questão.

2.5.1 Média-Variância

Markowitz (1952) introduz um dos primeiros modelos para gestão de carteiras de ativos. Este modelo, que ficou conhecido como modelo de Média-Variância, propõe as medidas de variância e o desvio-padrão como forma de análise de risco e a média como medida para o cálculo de retorno. Sob essa égide, o retorno de uma carteira pode ser analisado em função dos retornos passados de títulos individuais e dos respectivos percentuais alocados nos ativos. A equação 2.8 descreve essa medida.

$$E(R_c) = \sum_{i=1}^{n} w_i E(r_i) \tag{2.5}$$

Onde:
$E(R_c)$: retorno esperado carteira;
$E(r_i)$: retorno esperado do ativo i;
w_i: percentual do valor total alocado no ativo i.

O risco, neste modelo, é calculado pela dispersão dos resultados das ações em relação aos seus retornos médios. Em outras palavras, o grau de variação dos retornos define o grau de risco do investimento. Aqui o risco total também é calculado em função do risco individual de cada ativo (variâncias dos retornos individuais). A equação 2.6 demonstra a soma ponderada dessas variâncias.

$$\sigma^2 = \sum_{j,i=1}^{n} \sigma_{ij} w_i w_j \tag{2.6}$$

Onde:
σ^2: variância da carteira;
σ_{ij}: covariância entre os ativos i e j;
w_i: percentual do valor total alocado no ativo i.

A covariância, como demonstra a equação 2.6, também é um componente de grande influência no risco total de um portfólio. Securato (2010) citam que o problema geral deste modelo é encontrar a combinação ótima da carteira dado um retorno ou risco específicos, que foi encontrada com base em programação quadrática. Securato (2010) ainda mencionam que o modelo proposto implica na minimização do risco dado um nível de retorno desejado, sendo que os percentuais alocados devem obter somatório igual a 1, sob a suposição de não-nulidade para os respectivos pesos. As equações mostradas a seguir descrevem o modelo (LUENBERGER, 1998; ASSUNÇÃO, 2005).

$$Min \sum_{j,i=1}^{n} \sigma_{ij} w_i w_j \tag{2.7}$$

Sujeito a:

$$E(R_c) = \sum_{i=1}^{n} w_i E(r_i) \tag{2.8}$$

$$\sum_{i=1}^{n} w_i = 1 \qquad \text{com} \quad 1 \geq w_i \geq 0 \tag{2.9}$$

Em resumo, o modelo focado em Média-Variância prioriza a minimização de risco (diversificação).

2.5.2 Semi-Variância e *Downside Risk*

No artigo de 1959, Markowitz (1959) aborda as críticas ao seu modelo original de 1952, levantadas porRoy (1952), que propôs uma abordagem de análise voltada para as perdas, conhecida como o modelo de *Downside Risk*. Roy destacou a importância de selecionar investimentos com menores probabilidades de gerar retornos abaixo de um limiar esperado. O *Downside Risk*, que aponta o risco de um ativo ou portfólio render abaixo do retorno esperado, foca especificamente nas perdas potenciais, uma métrica crucial para investidores preocupados com resultados negativos mais do que com a volatilidade global.

A adoção do conceito de *Downside Risk* por Roy (1952) inspirou Markowitz (1959) a incorporar a Semi-Variância como uma medida alternativa, mais adequada tanto para refletir as preferências dos consumidores quanto para ajustar-se a retornos de ativos que não seguem uma distribuição normal (SECURATO, 2010). Diferente da variância, a Semi-Variância apenas considera variações de retorno que ficam abaixo da média ou de um nível alvo específico, concentrando-se, portanto, no risco de declínio. Esta medida se torna uma ferramenta essencial para investidores que buscam avaliar o risco de maneira mais alinhada às suas preocupações com perdas, em detrimento de uma análise que considere apenas a volatilidade total.

O uso da Semi-Variância como medida de risco prioriza a minimização de risco, especificamente o risco associado a resultados negativos.

2.5.3 Índice de Sharpe

Baseando-se no trabalho de Markowitz (1959), Sharpe (1966) desenvolveu um índice que apresenta o desempenho de um investimento levando em consideração o risco associado ao portfólio. Este índice proporciona uma avaliação do retorno excedente em relação ao risco assumido (LOCATELLI RONALDO L. E DE BARROS REIS, 2018). A Equação 2.10 mostra o calculo do IS.

$$IS = \frac{(R_i - R_f)}{\sigma_p} \tag{2.10}$$

Onde:
IS: índice de Sharpe;
R_i: retorno do ativo/carteira analisada;
R_f: retorno da taxa livre de risco;
σ_p: desvio padrão da carteira (risco).

O IS serve como um parâmetro que avalia o retorno ajustado ao risco de um portfólio. Quanto mais elevado for o valor do índice, maior será o retorno obtido por cada unidade de risco assumida, indicando um desempenho mais eficiente do portfólio. Por outro lado, um índice com valor negativo indica que o fundo está performando abaixo do ponto de referência escolhido (LOCATELLI RONALDO L. E DE BARROS REIS, 2018). Esse índice foca na maximização do retorno de um portfólio.

2.6 Técnicas de Otimização Computacionais

Nessa parte são discutidos os algoritmos de otimização mais comumente utilizados e indicados pela literatura para processos que envolvem otimização vetorial.

2.6.1 Algoritmos Genéticos

Os Algoritmos Genéticos representam uma classe popular de algoritmos de otimização inspirados no processo de seleção natural e evolução biológica. O conceito de AG foi introduzido por Holland (1975) em um livro chamado *Adaptation in Natural and Artificial Systems*, publicado em 1975. Neste livro, Holland (1975) descreveu como a seleção natural e a genética poderiam ser aplicadas a problemas de otimização e busca.

2.6.1.1 Funcionamento

Os AGs operam em um processo de seleção natural, recombinação genética e mutação, que simula o processo evolutivo observado na natureza. O processo começa com uma população inicial de soluções candidatas (indivíduos), que representam diferentes combinações de variáveis ou atributos. Cada indivíduo é avaliado em relação ao seu desempenho, utilizando uma função de avaliação que reflete os objetivos da otimização, como maximização de retorno ou minimização de risco. Os indivíduos são então selecionados para reprodução com base em seu desempenho. A recombinação genética ocorre através do cruzamento de informações entre os indivíduos selecionados, resultando na criação de novos indivíduos, chamados de descendentes. Essa recombinação mimetiza o conceito de *"crossover"* genético na biologia. Além disso, a mutação é aplicada aleatoriamente em certos atributos dos descendentes, introduzindo uma dose de aleatoriedade que permite explorar regiões desconhecidas do espaço de solução.

2.6.1.2 Aplicação ao problema

Em contextos financeiros, os Algoritmos Genéticos têm se mostrado eficazes para resolver problemas de otimização de portfólios. Esses algoritmos podem lidar com portfólios que envolvem uma grande quantidade de ativos e consideram múltiplos critérios, como retorno esperado, risco, restrições de alocação e limites de exposição. Conforme pontuado por Eiben A. E. e Smith (2003), a capacidade dos AGs de explorar espaços de solução complexos e não lineares faz com que eles sejam especialmente adequados para casos em que as relações entre ativos podem ser altamente interdependentes e não triviais.

2.6.2 Têmpera Simulada

A Têmpera Simulada (TS) é uma técnica de otimização estocástica inspirada no processo físico chamado "recozimento", que é usado na metalurgia para melhorar a estrutura cristalina de materiais. Essa técnica foi proposta por Vecchi (1983) como uma abordagem para resolver problemas de otimização combinatória. O seu objetivo é encontrar a solução ótima (ou uma solução próxima da ótima) para um problema, mesmo em espaços de busca complexos com muitos mínimos locais. A técnica é especialmente útil em problemas de otimização que envolvem muitas variáveis e onde é difícil garantir que a melhor solução seja encontrada usando métodos determinísticos tradicionais.

2.6.2.1 Funcionamento

O funcionamento da Têmpera Simulada é inspirado no processo de recozimento de metais. Em metalurgia, quando um metal é aquecido a altas temperaturas e, em seguida, resfriado lentamente, suas partículas têm mais liberdade para se moverem, resultando em uma estrutura cristalina mais estável. De maneira análoga, a Têmpera Simulada começa com uma solução inicial para o problema e, em seguida, faz uma busca aleatória no espaço de soluções, permitindo a aceitação de soluções piores com uma probabilidade controlada. O controle de temperatura é seu aspecto chave. Inicialmente, a temperatura é alta, permitindo que o algoritmo aceite soluções piores com maior probabilidade. Conforme o algoritmo avança, a temperatura é gradualmente reduzida, diminuindo a probabilidade de aceitar soluções piores e fazendo com que o algoritmo convirja para uma solução mais próxima da ótima ou ótimo global. Um pseudocódigo baseado no algoritmo proposto por Vecchi (1983) é representado no Quadro 1.

Quadro 1 – Pseudocódigo do Algoritmo de Têmpera Simulada

1. Inicie com um estado inicial s_0.
2. Repita para k de 0 até k_{max} (não incluindo k_{max}):
   a. Calcule a temperatura T usando uma função de temperatura que depende do progresso do algoritmo.
   b. Escolha um vizinho aleatório s_{new} do estado atual s.
   c. Se a probabilidade $P(E(s), E(s_{new}), T)$ for maior ou igual a um número aleatório entre 0 e 1:
      i. Atualize o estado atual para s_{new}.
3. Retorne o estado final s como a solução.

Fonte: Próprio Autor

2.7 Trabalhos Relacionados

Melquiades (2017) explora a aplicação de algoritmos de otimização avançados com o objetivo de alcançar uma diversificação e otimização eficiente de portfólios de ações. Este trabalho se fundamenta no uso de indicadores de risco, retorno e diversificação para aprimorar a seleção de ativos. Central para a metodologia proposta é a modelagem de um grafo que representa as relações entre os diferentes componentes do problema, bem como o desenvolvimento e implementação de algoritmos dedicados à otimização e diversificação de portfólios. A pesquisa avança para a construção de um protótipo funcional que facilita a simulação e avaliação de estratégias de investimento com base em dados históricos obtidos da BM&FBovespa, atual B3.

Dentre os objetivos específicos abordados, destacam-se: a concepção da estrutura do grafo, o desenvolvimento de algoritmos especializados para diversificação e otimização de portfólios, a criação de um protótipo para testes, a formulação de casos de teste realistas e a análise criteriosa dos resultados alcançados. Através desta investigação, o estudo demonstra a superioridade dos algoritmos propostos em equilibrar retorno e risco de maneira mais eficaz que as abordagens convencionais.

Além disso, o trabalho sublinha a relevância da modelagem matemática e da computação na elaboração e implementação de estratégias de investimento sofisticadas. Esta pesquisa estabelece um vínculo produtivo entre a ciência da computação e o campo das finanças, e evidenciando o potencial dos métodos computacionais avançados na solução de problemas complexos de otimização de portfólios.

Já o trabalho de Lang Jonas e Zielinski (2022), intitulado "Aplicação de Técnicas de *Annealing* para Otimização de Portfólios", em tradução livre, apresenta uma metodologia que emprega *annealing* simulado (tempera simulada), digital e quântico para a maximização de retornos e minimização de riscos em investimentos financeiros. Este estudo relaciona-se diretamente com a proposta deste trabalho, focando no uso de técnicas computacionais avançadas para solucionar problemas de alocação de ativos. Ambos os documentos compartilham a premissa de aplicar métodos quantitativos e de otimização para melhorar a eficiência dos portfólios de ações, embora adotem abordagens distintas dentro do espectro de *annealing*. Esta conexão evidencia a relevância de explorar diferentes estratégias de otimização computacional no campo das finanças, destacando a contribuição significativa dessas pesquisas para a literatura existente sobre otimização de portfólios financeiros.

3 Desenvolvimento

3.1 Materiais e Métodos

3.1.1 Metodologia

Para este trabalho, visou-se construir uma carteira composta por seis ativos de empresas de capital aberto no mercado brasileiro, dentre as 10 maiores empresas de capital aberto do Brasil no ano de 2018 (EXAME, 2018).

Para a metodologia de análise do resultados, foi preciso comparar dois anos consecutivos das séries histórias dos ativos escolhidos para o portfólio. A ideia inicial foi tentar comparar os anos de 2022 e 2023, porém o algoritmo da TS teve problemas para calcular os portfólios com dados de 2020, 2021 e 2022, anos em que os ativos foram muito afetados pela Pandemia de Covid-19, apresentando desvios padrão muito altos entre os portfólios gerados e seus resultados em termos de Risco e Retorno. O modelo não teve problemas para calcular carteiras utilizando os dados de 2023, 2019 e 2018. Por isso, foram escolhidos os anos de 2018 e 2019 para compor a nossa base de dados.

Assim, depois de delimitar os ativos, foram baixadas as séries históricas de cada um deles, considerando, primeiramente, o ano de 2018. Dessa forma, pode-se organizar uma matriz que continha cada um dos ativos dispostos por coluna, com seus respectivos valores de fechamento, dispostos por data nas linhas. Essa matriz de valores foi o principal artefato consultado durante todo o estudo. Um exemplo de como a matriz deveria se parecer é representado pela Tabela 3.1.

Tabela 3.1 – Exemplo de Matriz de Entrada

	Ativo 1	Ativo 2	Ativo 3
Data 1	100.0	200.0	300.0
Data 2	10.0	210.0	305.0
Data 3	50.0	205.0	310.0
Data 4	55.0	208.0	315.0

Fonte: Próprio Autor

É fundamental clarificar o conceito de portfólio conforme aplicado neste estudo. Aqui, um portfólio é definido por um conjunto de proporções, ou pesos, dispostos em um vetor, nos quais cada valor está delimitado entre 0 e 1 e sua soma totaliza 1, equivalente a 100%. Cada elemento deste vetor denota a fração do capital que seria alocada em um ativo específico. Neste contexto, o objetivo principal foi determinar a alocação ótima desses pesos em um portfólio, empregando o método da Têmpera Simulada como o algoritmo de otimização.

3.1.2 Base de Dados

Para a base de dados, foram selecionadas as séries das históricas entre o dia 1 de Janeiro de 2018 até 31 de Dezembro de 2018 para as ações ordinárias das empresas Ambev, Itaú Unibanco, Petrobras, Vale, Bradesco, Santander Brasil com seus respectivos códigos na B3 (Bolsa de Valores Brasileira): "ABEV3", "ITUB4", "PETR4", "VALE3", "BBDC4"e "SANB11". As séries históricas dessas empresas foram baixadas com apoio da biblioteca *yfinance*, do *Yahoo Finance*.

3.1.2.1 Estruturação dos Dados

Ao utilizar a biblioteca *yfinance* para baixar os preços de fechamento (*close*) das ações listadas na B3, os dados baixados são baixados e armazenados em uma estrutura de dados em memória denominada *DataFrame* do *pandas*, onde as colunas representam cada uma das ações, com seus respectivos símbolos seguidos por ".SA"para indicar que são ações da B3 (por exemplo, "VALE3.SA", "PETR3.SA", etc.). Um exemplo de *DataFrame* baixado dessa biblioteca é representado pela Tabela 3.2.

Tabela 3.2 – Exemplo de *DataFrame* Contendo o Fechamento de Ações em 2018

Data	VALE3.SA	PETR3.SA	ITUB3.SA	BBDC3.SA	JBSS3.SA	BBAS3.SA
2018-01-02	104.50	28.90	22.35	19.60	24.75	37.90
2018-01-03	105.00	29.20	22.55	19.85	25.00	38.20
2018-01-04	106.25	29.50	22.65	20.00	25.20	38.50
...	...	...	...	...	...	...
2018-12-29	110.00	32.00	23.00	20.50	26.00	39.00

Fonte: Próprio Autor

De acordo com a Tabela 3.2, as linhas representam as datas de negociação dessas ações dentro do período especificado. Os valores dentro do *DataFrame* são os preços de fechamento das ações nas datas correspondentes.

3.1.3 Implementações

Todas as implementações deste trabalho foram escritas com a linguagem *Python*, e lidas com o interpretador *Python* na versão 3.11.4.

3.1.3.1 Oráculo de Investimentos

A concepção do algoritmo Oráculo de Investimentos foi realizada para proporcionar uma compreensão mais aprofundada das dinâmicas envolvidas na otimização de carteiras de investimento em ações, explorando os potenciais retornos em um cenário idealizado onde fosse possível antecipar as tendências de valorização do mercado acionário. Este algoritmo é essencialmente empregado como uma métrica de referência, definindo um marco teórico para avaliar a eficácia de estratégias de investimento comparativamente às previsões geradas por modelos avançados, como a Têmpera Simulada e a abordagem de Markowitz para a composição de portfólios. Interessante notar que a implementação do Oráculo foi realizada de forma autônoma, sem o auxílio de bibliotecas externas.

Atuando como um benchmark de excelência, o Oráculo estabelece um parâmetro de comparação para outros modelos analíticos, como o Modelo com TS, permitindo uma avaliação criteriosa das estratégias de alocação de ativos em carteiras diversificadas. Tal análise se baseia na suposição teórica de previsibilidade completa das variações futuras do mercado. De maneira fundamental, o algoritmo delimita o potencial máximo de retorno, sugerindo que, dentro dos parâmetros definidos, o desempenho máximo esperado não excederia o limiar estabelecido por ele, fixando assim um limite superior para as expectativas de ganho. A implementação desse algoritmo pode ser consultada no Apêndice A.1.

3.1.3.2 Modelo com a Têmpera Simulada

Também foi feita uma primeira versão do Modelo utilizando o algoritmo de Têmpera Simulada, utilizando a biblioteca *numpy*, *datetime*, *pandas* e *yfinance*, que utiliza a base de dados do site *Yahoo Finance* para fazer *download* das séries históricas de ativos financeiros. Nesta primeira versão foi feita a implementação da Têmpera Simulada moldada ao problema de otimização de portfólios, utilizando dados fictícios na matriz de valores de entrada para melhor controle das saídas geradas pelo modelo. O foco dessa versão foi a modelagem da Função Objetivo, desenvolvimento dos cálculos de risco e retorno, além da própria função de Tempera Simulada.

A versão final da implementação do Modelo com TS pode ser encontrada no Apêndice A.2. Nela constam as funções descritas a seguir.

3.1.3.2.1 Cálculo de Retorno

O retorno também configura-se como uma medida essencial no cálculo do Índice de Sharpe (IS). É crucial para a avaliação da performance de investimentos mediante o ajuste de seus retornos pelo risco assumido. No contexto deste trabalho, foram conduzidas duas análises de retorno distintas, visando proporcionar uma avaliação abrangente da performance dos investimentos. Inicialmente, os retornos individuais das ações foram calculados, mediante a análise da variação percentual no preço de cada ativo ao longo do tempo, o que proporciona uma visão sobre o desempenho específico de cada empresa dentro do portfólio. Adicionalmente, realizou-se o cálculo do retorno do portfólio, tratando-se de uma medida agregada que reflete o desempenho global dos investimentos, considerando a diversificação entre os diferentes ativos. O cálculo do retorno da ações foi baseado na Equação 2.1 e do retorno do portfólio foi baseado na Equação 2.2.

3.1.3.2.2 Cálculo de Risco

O risco é fundamental na avaliação do IS, servindo como um indicador da volatilidade ou incerteza de retornos de um investimento. Ele é quantificado pelo desvio padrão dos retornos do ativo em um período específico, refletindo a amplitude com que os retornos podem variar em relação à média. Quanto maior o desvio padrão, maior o risco associado ao ativo, indicando uma variação mais ampla nos retornos esperados e, consequentemente, um impacto significativo no cálculo do IS, que busca medir a compensação de retorno ajustada ao risco. O cálculos dos riscos utilizados neste trabalho foram baseados nas equações 2.3 e 2.4.

3.1.3.2.3 Função Objetivo

Para este trabalho, o Índice de Sharpe (IS) foi escolhido como métrica de análise Retorno e Risco de um portfólio, compondo, portanto, a Função Objetivo da Têmpera. Neste caso, utiliza-se sua maximização, uma vez que um maior IS representa um maior retorno dado um certo risco. O cálculo da Função Objetivo foi baseado na maximização da Equação 2.10, levando em conta também os cálculos de retorno e risco já mencionados. Utilizou-se como R_f (retorno da taxa livre de risco) a taxa Selic do ano analisado, pois trata-se da taxa de juros referencial que é usada pelo Governo Federal para fixação da remuneração de títulos públicos, que são boas estimativas de ativos livres de risco.

3.1.3.2.4 Têmpera Simulada

A implementação da Têmpera Simulada se baseou em códigos abertos encontrados no *GitHub* e pelo pseudocódigo retirado e adaptado do trabalho de Vecchi (1983) e que é representado pelo Quadro 1.

3.1.3.2.5 Função Probabilidade de Aceitação

A Função Probabilidade de Aceitação na TS é essencial para permitir que o algoritmo escape de mínimos locais ao aceitar, com certa probabilidade, soluções piores que a atual. Essa probabilidade diminui conforme a "temperatura"do sistema é reduzida. No início, o algoritmo tem maior disposição para aceitar mudanças negativas, aumentando a exploração do espaço de soluções. À medida que a temperatura diminui, a aceitação de piores soluções torna-se menos provável, permitindo um refinamento em direção ao ótimo global. A Função Probabilidade de Aceitação é representada pelo Quadro 2.

Quadro 2 – Pseudocódigo da Função Probabilidade de Aceitação

1. Se a probabilidade $P(E(s), E(s_{new}), T)$ for maior ou igual a um número aleatório entre 0 e 1: a. Atualize o estado atual para s_{new}.

Fonte: Próprio Autor

3.1.3.3 Programa para Calcular Métricas de um Portfólio

Desenvolveu-se um algoritmo que aplica os mesmos procedimentos de cálculo de Retorno (conforme a Subseção 3.1.3.2.1) e de Risco (conforme a Subseção 3.1.3.2.2), projetado para processar quatro parâmetros essenciais: o ano de referência dos ativos, o capital inicial, o vetor de pesos do portfólio e a matriz de séries históricas dos ativos para o ano em questão. Este algoritmo tem como finalidade calcular as métricas de Retorno, Risco e Capital Final de um determinado portfólio. A razão para a criação deste algoritmo reside na necessidade de avaliar, de forma independente ao Modelo com TS, o desempenho de um portfólio específico. Detalhes adicionais sobre a implementação deste programa estão disponíveis no Apêndice A.3.

3.1.4 Melhorias do Modelo

A implementação foi sendo modificada de forma a obter resultados mais coerentes e com menor variação de valores entre si. Uma das melhorias feitas foi na função que gera a primeira solução de portfólio. Antes ela gerava valores aleatórios, que depois eram normalizados. Isso causava um maior desvio padrão entre os resultados obtidos como melhores portfólios. Para diminuir esse desvio, passou-se a gerar como primeira solução de portfólio uma lista de números cujos valores eram $1/n$, com n=6, que representa o número de ativos do portfólio. Ou seja, o vetor de pesos era inicializado com um valor médio. Isto fez o desvio padrão entre os resultados gerados diminuir.

Depois de julgar que o modelo, usando de entrada uma matriz fictícia de ações, estava gerando resultados coerentes, a matriz de dados de entrada foi alterada para a matriz real das séries históricas das ações.

3.2 Limitações

É importante destacar que para o cálculo de risco, utilizou-se a variância como medida, e não a semi-variância negativa. Ao optar pela variância como medida de risco, em detrimento da semi-variância negativa, adota-se uma abordagem que oferece uma perspectiva mais abrangente sobre a volatilidade dos retornos de um investimento. Esta escolha implica considerar tanto as flutuações positivas quanto as negativas em relação à média dos retornos, fornecendo uma visão geral da volatilidade total. Essa metodologia não distingue entre os movimentos de preço que são favoráveis ou desfavoráveis ao investidor, tratando ambos os tipos de variação de forma equânime.

Tal abordagem pode não ser inteiramente alinhada com as preocupações dos investidores mais avessos ao risco, que focam primariamente nas possíveis perdas — uma preocupação que a semi-variância negativa aborda ao considerar apenas as quedas nos retornos.

Além disso, a escolha da variância pode levar a uma diversificação de portfólio que visa mitigar a volatilidade total, sem dar atenção especial ao risco de baixa, o que poderia resultar em estratégias de alocação de ativos distintas. Essa diferença na abordagem da medida de risco pode, por conseguinte, influenciar significativamente a seleção e a composição dos ativos dentro de um portfólio.

A utilização da variância se alinha com muitos modelos financeiros tradicionais, como a Teoria Moderna do Portfólio de Markowitz, que considera a variância ou a covariância das taxas de retorno na construção de portfólios eficientes. Contudo, essa medida pode não refletir precisamente a aversão ao risco de investidores que dão maior peso às perdas potenciais do que às variações positivas. Dessa forma, enquanto a variância oferece uma medida padronizada de risco, incorporando tanto os ganhos quanto as perdas potenciais, ela pode não capturar completamente o aspecto da aversão ao risco relacionado especificamente ao risco de perdas, algo que é mais diretamente abordado pela semi-variância negativa.

4 Resultados

4.1 Primeiro Experimento

O primeiro experimento consistiu em gerar 10 portfólios a partir do algoritmo modelo com TS usando os dados das séries históricas de 2018. Como o algoritmo de TS tem como base a aceitação de soluções vizinhas com desempenho pior, probabilisticamente baseadas na temperatura corrente, foram realizadas 10 simulações no total. Essa escolha da quantidade de portfólios gerados (simulações) também foi feita pensando em gerar um valor razoável de saídas diferentes que não fossem muito demoradas para calcular e que mostrassem a tendência convergente entre os resultados. Para todos os resultados aqui descritos os valores de entrada para TS foram temperatura=1000.0, fator de resfriamento=0.9999 e passo=0.05. O valor de Capital Inicial também foi o mesmo em todas execuções, R$ 100.000,00 (cem mil reais). Os portfólios gerados e seus pesos são mostrados na Tabela 4.1.

Tabela 4.1 – Portfólios Gerados para 2018 e Seus Pesos

Portfólio	Pesos Portfólio					
	ABEV3	ITUB4	PETR4	VALE3	BBDC4	SANB11
1	0.000000%	0.001154%	0.002441%	17.490722%	51.378214%	31.127468%
2	0.000000%	0.000992%	0.003107%	17.485312%	51.381099%	31.129490%
3	0.000000%	0.001231%	0.001777%	17.485498%	51.381313%	31.130182%
4	0.000000%	0.014792%	0.000037%	17.486864%	51.370282%	31.128024%
5	0.000000%	0.002427%	0.000212%	17.487362%	51.384282%	31.125718%
6	0.000000%	0.004432%	0.014502%	17.490642%	51.365574%	31.124850%
7	0.000000%	0.017334%	0.003187%	17.484959%	51.372181%	31.122339%
8	0.000000%	0.001342%	0.001332%	17.483225%	51.386175%	31.127925%
9	0.000000%	0.003063%	0.004739%	17.487698%	51.380435%	31.124065%
10	0.000000%	0.004560%	0.009842%	17.485710%	51.375642%	31.124245%

Fonte: Próprio Autor

A Figura 4.1 mostra um Mapa de Calor representativo de um portfólio gerado, evidenciando como seriam as alocações para cada ativo. Escolheu-se mostrar apenas um porque os demais são numericamente similares.

Os resultados em termos das medidas de Retorno, Volatilidade (que foi utilizada como medida de Risco), Capital Final e IS são representados para cada um dos portfólios gerados na Tabela 4.2.

Os gráficos, a seguir, foram obtidos a partir de um dos portfólios gerados e eles foram escolhidos de forma a exemplificar o comportamento do modelo. A Figura 4.2 mostra o gráfico de temperatura por iteração, provando que algoritmo da TS funciona conforme o esperado, com

Figura 4.1 – Mapa de Calor para um Portfólio

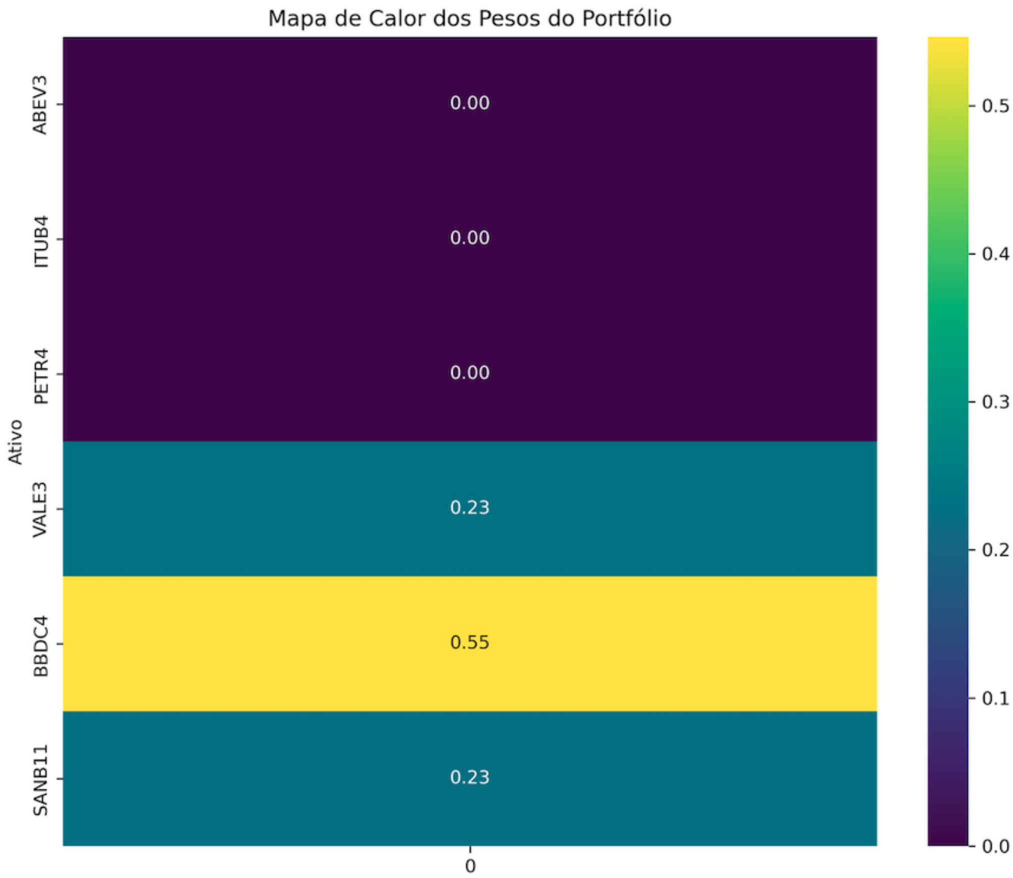

Fonte: Próprio Autor

Tabela 4.2 – Métricas dos Portfólios Gerados para 2018

Portfólio	**Retorno**	**Volatilidade**	**Capital Final**	**IS**
1	29.398918%	28.077070%	R$ 129398.92	0.815574
2	29.398367%	28.076415%	R$ 129398.37	0.815573
3	29.398427%	28.076444%	R$ 129398.43	0.815574
4	29.397750%	28.076121%	R$ 129397.75	0.815560
5	29.398988%	28.077119%	R$ 129398.99	0.815575
6	29.397696%	28.076206%	R$ 129397.70	0.815555
7	29.397625%	28.076205%	R$ 129397.62	0.815553
8	29.398528%	28.076554%	R$ 129398.53	0.815575
9	29.398660%	28.076929%	R$ 129398.66	0.815569
10	29.397904%	28.076275%	R$ 129397.90	0.815561

Fonte: Próprio Autor

uma queda logarítmica da temperatura ao longo do tempo, caracterizado pela iterações.

A Figura 4.3 mostra o comportamento do IS ao longo das iterações para um portfólio gerado. Durante as execuções, ele pode assumir valores melhores ou piores que as iterações anteriores, já que a TS pode aceitar soluções ruins, principalmente no início. Porém, ao fim,

Figura 4.2 – Gráfico de Temperatura x Iteração

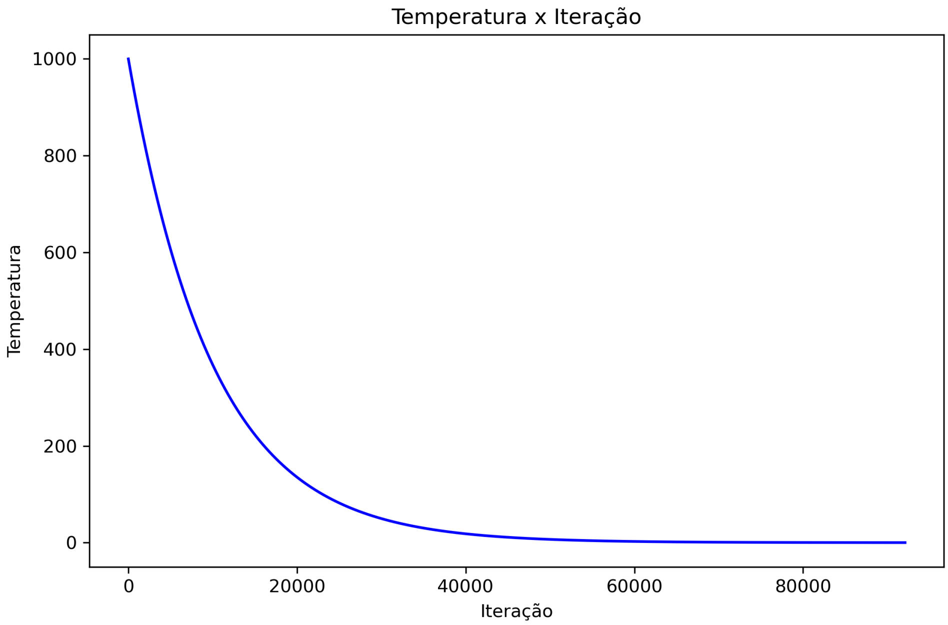

Fonte: Próprio Autor

termina-se com o valor máximo de IS encontrado, já que a Função Objetivo busca a maximização desse índice.

Figura 4.3 – Gráfico de IS x Iteração

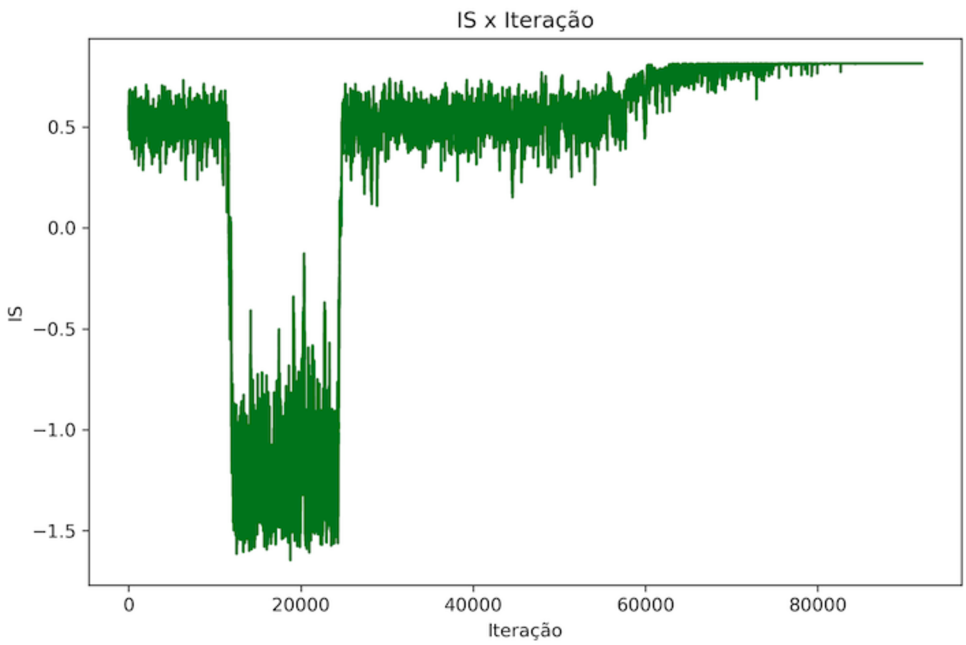

Fonte: Próprio Autor

O retorno se comporta de forma parecida ao IS durante as iterações, já que é diretamente proporcional a este. A Figura 4.4 exemplifica esse comportamento do retorno das iterações. Novamente, ao longo das iterações, valores melhores ou piores que os anteriores podem ser assumidos, mas, ao fim, a função tende a algum dos maiores valores encontrados para o retorno, não sendo, necessariamente, o maior, mas aquele que gera o maior IS.

Figura 4.4 – Gráfico de Retorno x Iteração

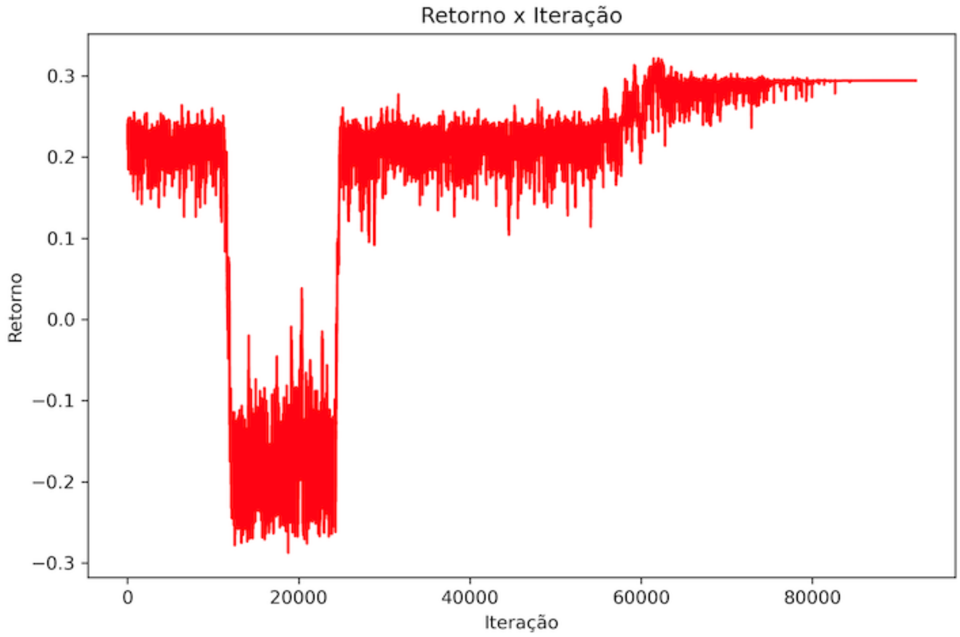

Fonte: Próprio Autor

O risco atua de maneira inversamente proporcional ao IS. A Figura 4.5 mostra essa tendência, com o gráfico do risco por interação. No fim das iterações, espera-se que o risco seja um valor minimizado, mas não necessariamente o menor valor encontrado, e sim aquele que gera o maior IS.

A tabela 4.3 resume os valores médios e os desvios padrão para as métricas de Retorno, Volatilidade, Capital Final e IS. Estes cálculos fornecem uma visão geral da performance e da variabilidade dos investimentos analisados, permitindo melhor compreensão dos riscos e retornos envolvidos.

Tabela 4.3 – Médias e Desvios Padrão das Métricas Financeiras para os Portfólios

Métrica	**Valor Médio**	**Desvio Padrão**
Retorno Médio	29.3983%	0.0005%
Volatilidade Média	28.0765%	0.0004%
Capital Final Médio	R$ 129,398.29	R$ 0.51
IS Médio	0.81557	0.000009

Fonte: Próprio Autor

Figura 4.5 – Gráfico de Risco x Iteração

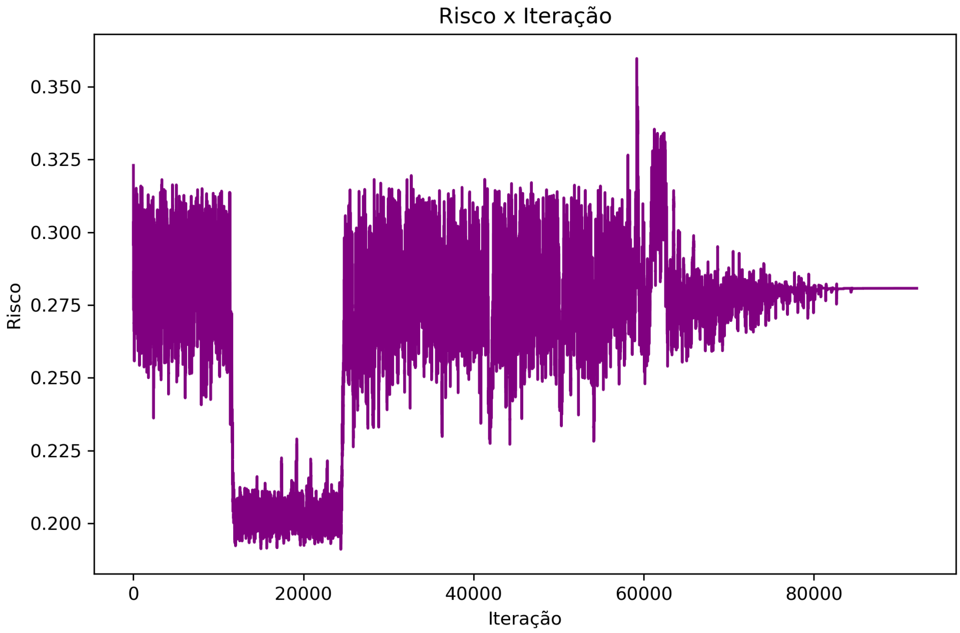

Fonte: Próprio Autor

4.2 Segundo Experimento

No segundo experimento o algoritmo de Oráculo de Investimentos foi executado utilizando como entradas os valores de fechamento do primeiro e do último dia de 2019 para os ativos escolhidos. Os pesos do portfólio neste algoritmo são diretamente proporcionais ao desempenho relativo de cada ativo, ajustados para garantir que apenas ativos com desempenho positivo sejam considerados para investimento. Isso reflete uma estratégia de investimento que prioriza ativos que tiveram um bom desempenho no período analisado, ajustando o portfólio para maximizar o retorno relativo. O capital inicial foi ajustado para R$ 100.000,00 (cem mil reais). Os valores obtidos para Capital Final e Ganho Percentual são apresentados na Tabela 4.4.

Tabela 4.4 – Resultados do Simulador Oráculo para 2019

Métrica	**Valor**
Capital Final	R$ 116,844.77
Ganho Percentual	16.8448%

Fonte: Próprio Autor

4.3 Terceiro Experimento

No terceiro experimento, utilizou-se o Programa para Calcular Métricas de um Portfólio com os pesos oriundos do Modelo desenvolvido no Primeiro Experimento. Esses pesos representam o portfólio calculado com base na média dos resultados das séries históricas de 2018, ajustados para os ativos selecionados e normalizados de modo que a soma totalize 1. Os pesos do portfólio obtidos foram [0,000000, 0,000051, 0,000041, 0,174868, 0,513775, 0,311265]. Com esses pesos, dados históricos de 2019 para os ativos em questão e um capital inicial de R$ 100.000,00 (cem mil reais), calcularam-se as métricas de desempenho do portfólio, conforme apresentado na Tabela 4.5.

Tabela 4.5 – Métricas para o Portfólio Gerado Aplicado em 2019

Métrica	**Valor**
Retorno	9.7936%
Volatilidade	22.4685%
Capital Final	R$ 109.793,62

Fonte: Próprio Autor

4.4 Análise dos Experimentos

A análise dos dados oriundos dos três experimentos revela que o Modelo obteve desempenho inferior ao *benchmark* estabelecido em 16,8448%, conforme indicado pelo Oráculo, sinalizando sua confiabilidade. No entanto, registrou um retorno significativo de 9.7936%, ultrapassando a Taxa Selic de 2019, cuja média foi de 5,5%. Além disso, o Modelo evidenciou variações mínimas nos desvios padrão entre os portfólios gerados, bem como para suas respectivas métricas de Retorno, Risco (Volatilidade) e Índice de Sharpe (IS), conforme ilustrado na Tabela 4.3. Esses resultados permitem afirmar que o Modelo desenvolvido apresenta um potencial significativo como ferramenta para a elaboração de estratégias de investimento de longo prazo.

Além disso, o uso da Têmpera Simulada para a otimização do portfólio demonstrou ser uma estratégia viável para a seleção de ativos. A capacidade do algoritmo de aceitar soluções piores no início (devido à "temperatura"inicial alta) e gradualmente convergir para uma solução ótima (à medida que a "temperatura"diminui) é um aspecto importante, pois permite uma exploração eficiente do espaço de soluções.

Finalmente, é válido acrescentar que o modelo proposto, baseado em TS, pode ser sensível às mudanças nas condições de mercado devido à sua dependência de dados históricos para a otimização de portfólios. Mercados financeiros são influenciados por uma ampla gama de fatores econômicos, políticos e sociais que podem mudar rapidamente, afetando a validade das premissas do modelo. A sensibilidade a essas mudanças pode resultar em desempenho sub-ótimo do portfólio em condições de mercado não previstas durante a fase de teste e otimização. Para os anos de 2020, 2021 e 2022, onde a economia foi amplamente afetada pela Pandemia de Covid-19, o modelo não apresentou resultados satisfatórios, mostrando uma grande variação entre os resultados dos portfólios gerados.

5 Considerações Finais

Este trabalho apresentou um estudo sobre a otimização de portfólios de ações utilizando o algoritmo de Têmpera Simulada, visando alcançar a maximização do retorno ajustado ao risco. Para alcançar o objetivo geral, foram estabelecidos objetivos específicos que guiaram o desenvolvimento do trabalho. A seguir, são retomados cada um desses objetivos específicos, discutindo como foram atingidos:

1. Delimitação dos indicadores de desempenho de ações: este objetivo foi alcançado através da análise dos indicadores financeiros mais relevantes para a avaliação de desempenho de ações. Com base nessa análise, selecionamos indicadores que oferecem uma visão abrangente do desempenho das ações dentro do portfólio otimizado.

2. Seleção de um conjunto de ações cotadas na B3: utilizou-se dados históricos de ações cotadas na B3 para compor o universo de investimento. A seleção foi feita considerando o potencial de retorno e a liquidez dos ativos, o que é fundamental para a aplicabilidade prática do portfólio otimizado.

3. Seleção e implementação do algoritmo de otimização: O algoritmo de Têmpera Simulada foi escolhido e implementado como método de otimização. A escolha se justifica pela capacidade do algoritmo de escapar de mínimos locais e encontrar soluções próximas ao ótimo global, demonstrando eficácia na otimização de portfólios. Além de contribuir para o acervo de pesquisas relacionadas.

4. Análise de simulações de investimento e comparações com *benchmarks*: as simulações realizadas com o portfólio otimizado demonstraram bons resultados da relação risco-retorno em comparação com *benchmarks* de mercado. Isso evidencia o potencial do uso de algoritmos de otimização avançados, como a Têmpera Simulada, na gestão de portfólios de investimento.

Portanto, conclui-se que o trabalho atingiu seu objetivo principal de otimizar portfólios de ações na B3, oferecendo contribuição tomadas de decisão dos investidores e gestores de fundos, além de contribuir para as pesquisas do meio acadêmico. A aplicação do algoritmo de Têmpera Simulada provou ser uma abordagem eficaz para a otimização de portfólios, abrindo caminho para futuras pesquisas e aplicações no campo financeiro.

5.1 Conclusão

A aplicação do algoritmo de Têmpera Simulada para a otimização de portfólios demonstrou ser eficiente, superando os desafios impostos pela volatilidade do mercado e as correlações entre os ativos. Os resultados obtidos confirmaram a hipótese inicial de que essa técnica poderia oferecer uma alternativa viável às abordagens tradicionais, configurando-se como uma boa ferramenta para análise da relação risco-retorno de um portfólio de ações.

Através da análise dos experimentos realizados, foi possível observar que o modelo proposto não apenas atingiu os objetivos específicos, como também ofereceu sugestões para a tomada de decisão em investimentos. Esse trabalho contribui enquanto pesquisa, fornecendo uma base para futuros estudos sobre a aplicação de algoritmos de otimização em finanças.

Além disso, este estudo abre caminho para a exploração de outras técnicas de otimização computacional no contexto financeiro. A integração de métodos computacionais avançados com a teoria financeira clássica representa uma fronteira promissora para a otimização de portfólios, com potencial para revolucionar as práticas de gestão de investimentos.

5.2 Trabalhos Futuros

Algumas propostas para a continuidade desse trabalho são:

1. Utilizar uma base de dados maior para otimização da TS;
2. Desenvolver técnicas de diversificação, para além da otimização apenas;
3. Utilizar outra métrica que não o IS para a Função Objetivo;
4. Comparar os resultados com de outras técnicas de otimização para o mesmo conjunto de ações e ano.

Referências

ASSUNÇÃO, O. L. do Valle Costa e Hugo Gonçalves Vieira de. Análise de risco e retorno em investimentos financeiros. Manole, 2005.

EIBEN A. E. E SMITH, J. E. *Introduction to Evolutionary Computing*. Springer, 2003. ISBN 3-540-40184-9. Disponível em: <http://www.cs.vu.nl/~gusz/ecbook/ecbook.html>.

EXAME, R. *As 100 maiores empresas de capital aberto*. [S.l.]: INFORMS, 2018. <https://exame.com/revista-exame/maiores-em-financas-2/>. Acessado em 19 de janeiro de 2024.

HOLLAND, J. H. *Adaptation in Natural and Artificial Systems*. Ann Arbor, MI: University of Michigan Press, 1975. Second edition, 1992.

LANG JONAS E ZIELINSKI, S. e. F. S. Strategic portfolio optimization using simulated, digital, and quantum annealing. *Applied Sciences*, v. 12, n. 23, 2022. ISSN 2076-3417. Disponível em: <https://www.mdpi.com/2076-3417/12/23/12288>.

LINTNER, J. The valuation of risk assets and the selection of risky investments in stock portfolios and capital budgets. *The Review of Economics and Statistics*, v. 47, p. 13–37, 1965. Disponível em: <https://api.semanticscholar.org/CorpusID:154937227>.

LOCATELLI RONALDO L. E DE BARROS REIS, T. L. e. L. J. E. e. R. W. Efficiency analysis of real estate investment funds in a period of economic crisis. *Revista Ibero-Americana de Estratégia*, v. 17, n. 2, p. 78–92, 2018.

LUENBERGER, D. G. *Investment Science*. [S.l.]: Oxford University Press, 1998.

MARKOWITZ, H. M. Portfolio Selection. *Journal of Finance*, v. 7, n. 1, p. 77–91, March 1952. Disponível em: <https://ideas.repec.org/a/bla/jfinan/v7y1952i1p77-91.html>.

MARKOWITZ, H. M. Portfolio selection: Efficient diversification of investments. Yale University Press, 1959.

MELQUIADES, L. P. Modelagem com algoritmos em grafos e evolutivos para o problema de diversificação e otimização de portfólios. Maringá, dez. 2017. Bacharelado em Ciência da Computação.

MONTINI, A. C. de Araújo e Alessandra de Á. Análise de métricas de risco na otimização de portfolios de ações. *Revista de Administração*, v. 50, n. 2, p. 208–228, 2015. ISSN 0080-2107. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0080210716303892>.

NETO, A. A. *Mercado Financeiro*. 12. ed.. ed. São Paulo: Atlas, 2014. ISBN 9788522423361.

NIKOLAEV A. G. E JACOBSON, S. Simulated annealing. In: ____. [S.l.: s.n.], 2010. v. 146, p. 1–39. ISBN 978-1-4419-1663-1.

ROY, A. D. Safety first and the holding of assets. *Econometrica: Journal of the econometric society*, JSTOR, p. 431–449, 1952.

SECURATO, A. C. de Araújo e Alessandra de Ávila Montini e J. R. Teoria do portfólio pós-moderna: um estudo sobre a semivariância. EAD/FEA/USP, 2010.

SHAHID MOHAMMAD E SHAMIM, M. e. A. Z. e. A. M. S. A novel evolutionary optimization algorithm based solution approach for portfolio selection problem. *IAES International Journal of Artificial Intelligence*, v. 11, n. 3, p. 843 – 850, 2022.

SHARPE, W. F. Capital Asset Prices: A Theory Of Market Equilibrium Under Conditions Of Risk. *Journal of Finance*, v. 19, n. 3, p. 425–442, September 1964. Disponível em: <https://ideas.repec.org/a/bla/jfinan/v19y1964i3p425-442.html>.

SHARPE, W. F. Mutual fund performance. *The Journal of business*, JSTOR, v. 39, n. 1, p. 119–138, 1966.

VECCHI, S. K. e C. Daniel Gelatt e M. P. Optimization by simulated annealing. *Science*, v. 220, n. 4598, p. 671–680, 1983.

WRIGHT, J. N. e S. J. *Numerical Optimization*. 2nd. ed. [S.l.]: Springer, 2006.

Apêndices

APÊNDICE A – Implementações

A.1 Implementação do Oráculo de Investimentos

```
def soma_positivos(vetor):
    return sum(x for x in vetor if x > 0)

def substitui_negativos_por_zero(vetor):
    return [max(0, x) for x in vetor]

def divide_positivos_por_soma_p(vetor, soma_p):
    return [0 if x <= 0 else x / soma_p for x in vetor]

def soma_valores(vetor):
    return sum(vetor)

def simulador_oraculo():
    capital_inicial = 100000 # Cem mil reais

    # Dados de 2019 para os 6 ativos do Portfolio
    vetor_preco_inicio = [1.614999961853027344e+01, 2.528800392150878906e+01, 3.700000000000000000e+01, 2.405999946594238281e+01, 4.391283035278320312e+01, 5.109000015258789062e+01]
    vetor_preco_final = [1.867000007629394531e+01, 2.717505645751953125e+01, 3.709999847412109375e+01, 3.018000030517578125e+01, 4.733061981201171875e+01, 5.329999923706054688e+01]

    vetor_ganho = [p2 - p1 for p1, p2 in zip(vetor_preco_inicio, vetor_preco_final)]
    vetor_ganho_relativo = [(g / p1) if p1 > 0 else 0 for g, p1 in zip(vetor_ganho, vetor_preco_inicio)]
    soma_p = soma_positivos(vetor_ganho_relativo)
    vetor_invest = substitui_negativos_por_zero(vetor_ganho_relativo)
    vetor_invest_normalizado = divide_positivos_por_soma_p(vetor_invest, soma_p)
    capital_investido = [capital_inicial * x for x in vetor_invest_normalizado]
    vetor_capital_final = [inv + inv * g for inv, g in zip(capital_investido, vetor_ganho_relativo)]
    capital_final = soma_valores(vetor_capital_final)
    ganho_percentual = (capital_final - capital_inicial) / capital_inicial

    return capital_final, ganho_percentual
```

```

capital_final, ganho_percentual = simulador_oraculo()
print(f"Capital Final: {capital_final}")
print(f"Ganho Percentual: {ganho_percentual * 100}%")
```

Algoritmo A.1 – Oráculo de Investimentos

A.2 Implementação do Modelo com Têmpera Simulada

```
import yfinance as yf
import numpy as np
import datetime as dt
import pandas as pd
import random
import math
import os
import csv
import seaborn as sns
import matplotlib.pyplot as plt
import time

ano_dos_ativos = 2018
folder = f'resultados_{ano_dos_ativos}'
lista_acoes = ["ABEV3", "ITUB4", "PETR4", "VALE3", "BBDC4", "SANB11"]
dict_retorno_ativo_livre_risco = {2018: 0.065, 2019: 0.055, 2023:
    0.1225}

def calcula_retorno_portfolio(portfolio, retornos):
    return np.sum(portfolio * retornos)

def calcula_retorno_periodo_total_acoes(dominio):
    n, m = dominio.shape
    array_retornos = np.zeros(m)
    for j in range(m):
        array_retornos[j] = (dominio[-1][j] - dominio[0][j]) / dominio
    [0][j]
    return array_retornos

def calcula_covariancia_acoes(variacao_precos):
    covariancia = variacao_precos.cov()
    return covariancia

def calcula_variacao_precos(precos):
    prices_df = pd.DataFrame(precos, columns=['Column_A', 'Column_B', '
    Column_C', 'Column_D', 'Column_E', 'Column_F'])
    variacao_precos = prices_df / prices_df.shift(1) - 1
    variacao_precos = variacao_precos.dropna()
```

```
    return variacao_precos

def calcula_volatilidade_portfolio(pesos_portfolio, covariancia, tamanho_amostra):
    desvio_padrao_por_dia = np.sqrt(np.dot(np.dot(pesos_portfolio.T, covariancia), pesos_portfolio))
    desvio_padrao_total = desvio_padrao_por_dia * np.sqrt(tamanho_amostra)
    return desvio_padrao_total

def funcao_objetivo(pesos_portfolio, precos, taxa_retorno, covariancia, retorno_ativo_livre_risco):
    qtd_dias_variacoes_preco = len(precos)-1
    risco_portifolio = calcula_volatilidade_portfolio(pesos_portfolio, covariancia, qtd_dias_variacoes_preco)
    retorno_portfolio = calcula_retorno_portfolio(pesos_portfolio, taxa_retorno)
    sharpe = (retorno_portfolio - retorno_ativo_livre_risco) / risco_portifolio
    return sharpe


def probabilidade_aceitacao(melhor_valor_objetivo, novo_valor_objetivo, temperatura):
    sorteio = random.random()
    probabilidade = pow(math.e, (- novo_valor_objetivo - melhor_valor_objetivo) / temperatura)
    return  sorteio < probabilidade


def normaliza_vetor(vetor):
    normalizado = []
    for i in range(len(vetor)):
        normalizado.append((vetor[i] - min(vetor)) / (max(vetor) - min(vetor)));
    return normalizado / np.sum(normalizado)

def distribui_vetor(vetor):
    return vetor / np.sum(vetor)

def tempera_simulada(precos, taxa_retorno, covariancia, retorno_ativo_livre_risco, tot_dias_dados, metricas_iteracoes, temperatura=1000.0, resfriamento=0.9999, passo=0.05):
    n, m = precos.shape
    pesos_portfolio = gerar_primeira_solucao(precos)

    pesos_melhor_portfolio = np.copy(pesos_portfolio)
```

```
    melhor_valor_objetivo = funcao_objetivo(pesos_melhor_portfolio, precos, taxa_retorno, covariancia, retorno_ativo_livre_risco)

    contador = 0

    # enquanto a temperatura nao foi quase zerada
    while temperatura > 0.1:
        novo_portfolio = np.copy(pesos_portfolio)

        # escolher uma posicao e alterar ela de acordo com o passo.
        i = np.random.choice(range(m), size=1, replace=False)
        # direcao e um valor float aleatorio entre -passo e +passo
        direcao = np.random.uniform(-passo, passo)

        if novo_portfolio[i] + direcao > 0:
            novo_portfolio[i] = novo_portfolio[i] + direcao
        else:
            novo_portfolio[i] = novo_portfolio[i] - direcao

        novo_portfolio = normaliza_vetor(novo_portfolio)
        novo_valor_objetivo = funcao_objetivo(novo_portfolio, precos, taxa_retorno, covariancia, retorno_ativo_livre_risco)

        prob_aceita_solucao_ruim = probabilidade_aceitacao(melhor_valor_objetivo, novo_valor_objetivo, temperatura)

        if (novo_valor_objetivo > melhor_valor_objetivo or prob_aceita_solucao_ruim):
            pesos_portfolio = np.copy(novo_portfolio)
            pesos_melhor_portfolio = np.copy(pesos_portfolio)
            melhor_valor_objetivo = novo_valor_objetivo

        metricas = gerar_metricas_para_iteracao(contador, taxa_retorno, covariancia, retorno_ativo_livre_risco, pesos_melhor_portfolio, tot_dias_dados, temperatura)
        metricas_iteracoes.append(metricas)
        contador += 1
        temperatura = temperatura * resfriamento
    print('Contador: ', contador)
    return pesos_melhor_portfolio


def gerar_metricas_para_iteracao(contador, taxa_retorno, covariancia, retorno_ativo_livre_risco, pesos_portfolio, tot_dias_dados, temperatura):
    retorno_portfolio = calcula_retorno_portfolio(pesos_portfolio, taxa_retorno)
```

```
    risco_portifolio = calcula_volatilidade_portfolio(pesos_portfolio, covariancia, tot_dias_dados)
    sharpe = (retorno_portfolio - retorno_ativo_livre_risco)/risco_portifolio

    return {
        'Iteracao': contador,
        'Retorno': retorno_portfolio,
        'Risco': risco_portifolio,
        'IS': sharpe,
        'Temperatura': temperatura}

def gerar_primeira_solucao(precos):
    # para diminuir a aleatoriedade: calcular os pesos de retorno do dominio normalizados ou usar tudo igual
    n, m = precos.shape
    unitario = [1] * m
    solucao = distribui_vetor(unitario)
    return solucao

def gerar_csv(precos, nome_arquivo):
    n = 10

    # cabecalhos para o arquivo CSV
    cabecalhos = ['Pesos Portfolio', 'Retorno', 'Volatilidade', 'Capital Final', 'IS']
    resultados = []

    for _ in range(n):
        resultado = resultados_tempera(precos)
        resultados.append({
            'Pesos Portfolio': ' '.join(map(lambda x: f"{x*100:.6f}%", resultado[0])),  # converter a lista de pesos em string
            'Retorno': f"{resultado[1]*100:.6f}%",
            'Volatilidade': f"{resultado[2]*100:.6f}%",
            'Capital Final': f"{resultado[3]:.6f}",
            'IS': f"{resultado[4]:.6f}",
        })

    with open(nome_arquivo, 'w', newline='') as arquivo_csv:
        escritor = csv.DictWriter(arquivo_csv, fieldnames=cabecalhos)
        escritor.writeheader()
        for resultado in resultados:
            escritor.writerow(resultado)

    print("CSV gerado.")

```

```
def vetor_para_df(vetor_pesos, num_ativos):
    num_execucoes = len(vetor_pesos) // num_ativos

    if len(vetor_pesos) % num_ativos != 0:
        raise ValueError("O tamanho do vetor nao e divisivel pelo numero
    de ativos.")

    matriz_pesos = np.array(vetor_pesos).reshape(num_execucoes,
    num_ativos)
    df_pesos = pd.DataFrame(matriz_pesos, columns=lista_acoes)

    return df_pesos

def criar_mapa_calor_pesos(df_pesos, salvar_imagem=True):
    caminho_imagem=f'{folder}/mapa_calor_pesos_{ano_dos_ativos}'
    plt.figure(figsize=(10, 8))
    sns.heatmap(df_pesos.transpose(), cmap='viridis', annot=True, fmt="
    .2f")

    plt.title('Mapa de Calor dos Pesos do Portfolio')
    plt.xlabel('Execucao')
    plt.ylabel('Ativo')

    if salvar_imagem:
        plt.savefig(f'{caminho_imagem}_{time.time()}.png', format='png',
    dpi=300)
    plt.show()

def plotar_metricas(df, salvar_imagem=True):
    fig, axs = plt.subplots(2, 2, figsize=(15, 10))  # Cria uma figura
    com subplots
    caminho_imagem = f'{folder}/grafico_{ano_dos_ativos}'

    # Temperatura x Iteracao
    axs[0, 0].plot(df['Iteracao'], df['Temperatura'], color='blue')
    axs[0, 0].set_title('Temperatura x Iteracao')
    axs[0, 0].set_xlabel('Iteracao')
    axs[0, 0].set_ylabel('Temperatura')

    # IS x Iteracao
    axs[0, 1].plot(df['Iteracao'], df['IS'], color='green')
    axs[0, 1].set_title('IS x Iteracao')
    axs[0, 1].set_xlabel('Iteracao')
    axs[0, 1].set_ylabel('IS')

    # Retorno x Iteracao
    axs[1, 0].plot(df['Iteracao'], df['Retorno'], color='red')
```

```
    axs[1, 0].set_title('Retorno x Iteracao')
    axs[1, 0].set_xlabel('Iteracao')
    axs[1, 0].set_ylabel('Retorno')

    # Risco x Iteracao
    axs[1, 1].plot(df['Iteracao'], df['Risco'], color='purple')
    axs[1, 1].set_title('Risco x Iteracao')
    axs[1, 1].set_xlabel('Iteracao')
    axs[1, 1].set_ylabel('Risco')

    plt.tight_layout()  # ajusta automaticamente os parametros dos subplots para dar espaco entre eles
    if salvar_imagem:
        plt.savefig(f'{caminho_imagem}_{time.time()}.png', format='png', dpi=300)
    plt.show()

def resultados_tempera(precos):
    metricas_iteracoes = []
    variacao_precos = calcula_variacao_precos(precos)
    tot_dias_dados = len(variacao_precos)
    covariancia = calcula_covariancia_acoes(variacao_precos)
    taxas_de_retornos = calcula_retorno_periodo_total_acoes(precos)

    retorno_ativo_livre_risco = dict_retorno_ativo_livre_risco[ano_dos_ativos]
    pesos_portfolio = tempera_simulada(precos, taxas_de_retornos, covariancia, retorno_ativo_livre_risco, tot_dias_dados, metricas_iteracoes = [])

    df_metricas = pd.DataFrame(metricas_iteracoes)
    plotar_metricas(df_metricas)

    capital_inicial = 100000.0  # Cem mil reais

    retorno_portfolio = calcula_retorno_portfolio(pesos_portfolio, taxas_de_retornos)
    capital_final = capital_inicial * (1 + retorno_portfolio)
    risco_portifolio = calcula_volatilidade_portfolio(pesos_portfolio, covariancia, tot_dias_dados)
    sharpe = (retorno_portfolio - retorno_ativo_livre_risco)/risco_portifolio

    df = vetor_para_df(pesos_portfolio, 6)
    criar_mapa_calor_pesos(df)

    return pesos_portfolio, retorno_portfolio, risco_portifolio,
```

```
    capital_final, sharpe


if (f'precos_{ano_dos_ativos}.csv' not in os.listdir()):
    lista_acoes_sa = [acao + ".SA" for acao in lista_acoes]
    inicio = dt.date(ano_dos_ativos, 1, 1)
    final = dt.date(ano_dos_ativos, 12, 31)
    precos = yf.download(lista_acoes_sa, inicio, final)['Close']

    np.savetxt(f'precos_{ano_dos_ativos}.csv', precos, delimiter=",")
else:
    precos = np.loadtxt(f'precos_{ano_dos_ativos}.csv', delimiter=",")

gerar_csv(precos, f'resultados_ts_{ano_dos_ativos}.csv')
```

Algoritmo A.2 – Modelo com Têmpera Simulada

A.3 Implementação do Programa para Calcular Métricas de um Portfólio

```
import numpy as np
import pandas as pd

def calcula_retorno_portfolio(portfolio, retornos):
    return np.sum(portfolio * retornos)

def calcula_retorno_periodo_total_acoes(dominio):
    n, m = dominio.shape
    array_retornos = np.zeros(m)
    for j in range(m):
        array_retornos[j] = (dominio[-1][j] - dominio[0][j]) / dominio[0][j]
    return array_retornos

def calcula_covariancia_acoes(variacao_precos):
    covariancia = variacao_precos.cov()
    return covariancia

def calcula_variacao_precos(precos):
    prices_df = pd.DataFrame(precos, columns=['Column_A', 'Column_B', 'Column_C', 'Column_D', 'Column_E', 'Column_F'])
    variacao_precos = prices_df / prices_df.shift(1) - 1
    variacao_precos = variacao_precos.dropna()
    return variacao_precos

```

```python
def calcula_volatilidade_portfolio(pesos_portfolio, covariancia, tamanho_amostra):

    desvio_padrao_por_dia = np.sqrt(np.dot(np.dot(pesos_portfolio.T, covariancia), pesos_portfolio))
    desvio_padrao_total = desvio_padrao_por_dia * np.sqrt(tamanho_amostra)

    return desvio_padrao_total

def calcula_metricas(pesos_portfolio, precos, capital_inicial):
    variacao_precos = calcula_variacao_precos(precos)
    tot_dias_dados = len(variacao_precos)
    covariancia = calcula_covariancia_acoes(variacao_precos)
    taxas_de_retornos = calcula_retorno_periodo_total_acoes(precos)
    retorno_portfolio = calcula_retorno_portfolio(pesos_portfolio, taxas_de_retornos)
    capital_final = capital_inicial * (1 + retorno_portfolio)
    risco_portifolio = calcula_volatilidade_portfolio(pesos_portfolio, covariancia, tot_dias_dados)

    return pesos_portfolio, retorno_portfolio, risco_portifolio, capital_final

ano_dos_ativos = 2019
capital_inicial = 100000.0
pesos_portfolio =  np.array([0.000000, 0.000051, 0.000041, 0.174868, 0.513775, 0.311265])

precos = np.loadtxt(f'precos_{ano_dos_ativos}.csv', delimiter=",")

result = calcula_metricas(pesos_portfolio, precos, capital_inicial)
print(f'Retorno: {result[1]*100}%. Volatilidade: {result[2]*100}%. Capital Final: R$ {result[3]}.')
```

Algoritmo A.3 – Calcular Métricas de um Portfólio